Oppgave: diabetesrisiko – estimator Dat158

Gruppemedlem: Makka Sugaipova

Omfang

Ifølge Norsk Helseinformatikk (u.å.) er type 2-diabetes en kronisk sykdom som kjennetegnes ved mangel på hormonet insulin eller dårlig virkning av insulin. Den viktigste årsaken til type 2 diabetes er overvekt og usunn livsstil, men også arv kan spille en rolle. Ved tidlig oppdagelse hjelper mye og er viktig, fordi behandling og livsstilendringer kan hindre alvorlige komplikasjoner som kan oppstå. For eksempel hjerte- og karsykdom, nyreskade og synstap.

Målet med oppgaven er å kunne utvikle en nettapplikasjon der bruker legger inn 8 helsemålinger, f.eks: blodsukker, BMI, blodtrykk og aldersgruppe og får et estimat av sannsynligheten for at man har diabetes. Løsning er da tenkt som et verktøy for tidlig risikovurdering og ikke selve diagnosen. En høy risiko kan være et tegn på å kontakte lege for potensiell testing.

Problemløsning til diagnosen stilles av en lege og man gjør det ved hjelp av blodprøve. For å vurdere hvem som bør testes finnes det spørreskjemaer eller at helsepersonell også bruker tommelfingerregler, f.eks: høyt blodsukker tilsier videre utredning.

I dette prosjektet har man testet en slik enkel regel som baseline og den har fanget opp 63% av pasientene med diabetes, men overså over en tredjedel av dem.

Og hvorfor bruker man maskinlæring til akkurat dette? Diabetesrisiko avhenger av flere faktorer samtidig og sammenhengene mellom dem er ikke nødvendigvis linære. En ML-modell kan lære hvordan ulike testene/målingene virker sammen. Dermed kan den gi en mer presis vurderingen en enkelt terskelverdi. I tillegg gir også modellen en sannsynlighet i stedet for kun ja/nei svar, og gjør det lettere å prioritere hvem som bør følges videre.

I oppgaven har jeg valgt målgruppe primært i helsetjeneste, f.eks fastlegekontor og bedriftshelsetjenester som ønsker en rask førstevurdering basert på målinger de allerede har. Sekundært kan løsningen brukes i undervisning hvor det vises hvordan ulike risikofaktorer kan påvirke diabetesrisiko for type 2.

System og pipeline: løsning består av tre deler:

1. Databehandling: rensing av manglende verdier og skalering
2. ML-modell: trent i Python med scikit-learn (Pedregosa et al., 2011) og lagret som fil

3. Nettside: laget med Gradio (Abid et al., 2019), der brukeren skriver inn verdier og modellen returnerer en risikooprediksjon

Databehandling og modellen er pakket i en scikit-learn-pipline. Dermed behandles nye data fra nettsiden nøyaktig likt som treningsdataene. Hvis man endrer rensingen eller hvilke features som brukes, må både modellen og inputfeltene på nettsiden oppdateres samtidig.

Verdien av løsningen ligger i å oppdage flere personer med diabetes tidligere, slik at de kan få behandlingen før komplikasjoner oppstår. Komplikasjoner gir store kostnader for både helsevesenet og den enkelte, hver bruker som fange opp tidlig, representerer derfor en mulig besparelse og en helsegevinst. Samtidig må løsningen ikke gi falske alarm at legene bruker tid på friske personer.

Selve prosjektet krever lite beregningskraft. Datasettet er lite på 768 rader og modellene trenes på sekunder på en vanlig bærbar laptop. Det brukes kun gratis verktøy: Python, scikit-learn og Gradio.

Datasettet er ubalansert (34,9 % har diabetes). Det gjør accuracy misvisende: en modell som alltid svarer «ikke diabetes», får 64,9 % accuracy uten å finne en eneste syk person. Jeg bruker derfor følgende metrikker

Recall(hovedmetrikk): andelen av de faktisk syke som modellen fanger opp. I en screeningsituasjon er det verre å overse en syk person (falsk negativ) enn å gi en falsk alarm (falsk positiv) fordi en falsk alarm bare fører til en ekstra blodprøve.

Precision: andelen av de som får "høy risiko", som faktisk er syke. Lav precision betyr mange unødvendige legebesøk.

Precision: andelen av de som får "høy risiko", som faktisk er syke. Lav precision betyr mange unødvendige legebesøk.

F1-score: balansen mellom precision og recall.

ROC AUC: hvor godt modellen skiller mellom syke og friske, uavhengig av valgt terskel.

Accuracy: Rapporteres for sammenligning med andre studier.

Software-metrikker: responstid på nettsiden (mål: under 1 sekund per prediksjon) og at siden er tilgjengelig.

Krav for at prosjektet skal være en suksess**:** Modellen skal slå den enkle blodsukker-regelen på testsettet, og målet er recall ≥ 0,75 uten at precision faller under ca. 0,55. Nettsiden skal være enkel å bruke og gi svar umiddelbart.

I en reell situasjon ville suksess også bli målt i antall nye diabetestilfeller oppdaget tidlig og i tilbakemeldinger fra helsepersonell. Det ligger utenfor rammene av dette prosjektet.

Data

Jeg bruker Pima Indians Diabetes Database, som opprinnelig kommer fra National Institute of Diabetes and Digestive and Kidney Diseases (NIDDK) i USA (Smith et al., 1988) og er tilgjengelig på Kaggle (UCI Machine Learning, 2016). Datasettet er offentlig og anonymisert.

Datasettet består av 768 pasienter og 8 numeriske målinger:

Måling	beskrivelse
Pregnancies	Graviditet, antall graviditerer
Glucose	Blodsukker 2 timer etter glukosebelastningstest (mg/dL)
Bloodpressure	Diastolisk blodtrykk (mm Hg)
SkinThickness	Hudfoldtykkelse på triceps (mm)
Insulin	Seruminsulin etter 2 timer (µU/ml)
BMI	Kroppsmasseindeks (kg/m^2)
DiabetesPedigreeFunction	Mål på arvelig disposisjon basert på familiehistorikk
Age	Alder

Labels

Målvariabelen outcome angir om pasienten har diabetes (1) eller ikke (0). Problemet er derfor supervised binær klassifikasjon. Labelen er satt av helsepersonell basert på medisinske kriterier i den opprinnelige studien, så jeg trenger ikke lage labels selv. Fordi de bygger på standardiserte medisinske tester, regner jeg dem som konsistente.

Mengde data: 768 pasienter er lite, men tilstrekkelig for enkle modeller med 8 målinger. Mer data vil gi bedre og mer stabil resultater, spesielt for de mer fleksible modellene. Jeg bruker kryssvalidering for å få pålitelige estimater til tross for det lille datasettet.

Utforskende analyse (EDA):

Klassefordeling: 500 pasienter (65,1%) har ikke diabetes og 268 (34,9%) har diabetes. Datasettet er altså ubalansert.

Korrelasjon med outcome: glucose har klart sterkest sammenheng med diabetes (0,47), etterfulgt av BMI (0,29), Age (0,24) og Pregnancies (0,22). BloodPressure og SkinThickness har svak sammenheng (0,07).

Korrelasjon mellom featues: age og pregnancies henger sammen (0,54), noe som er naturlig. Det samme gjelder SkinThickness og Insulin (0,44).

Datakvalitet og rensing

- Flere kolonner inneholder verdien 0 der det er medisinsk umulig, f.eks blodsukker eller BMI lik 0. disse nullene betyr i praksis at målingen mangler:

Måling	Antall 0-verdier	Andel
Insulin	374	48,7 %
SkinThickness	227	29,6%
Bloodpressure	35	4,6 %
BMI	11	1,4 %
Glucose	5	0,7%

Nesten halvparten av pasientene mangler insulinverdi. Å fjerne disse radene ville ført til at man mistet mye data. Man erstatter derfor 0-verdiene med medianen for hver kolonne. Medianen beregnes kun på treningsdataene, slik at informasjon fra testsettet ikke lekker inn i modellen. Pregnancies = 0 En gyldig verdi og endres ikke.

Oppdeling

Dataene deles i 80 % trening (614 pasienter) og 20 % test (154 pasienter), med stratify slik at andelen med diabetes er lik i begge settene. Testsettet holdes helt adskilt til den endelige evalueringen.

Representasjon og skalering

Alle features/målinger er numeriske, så det trengs ingen koding av kategorier.
Featurene har svært ulike skalaer (Insulin går opp til over 800, mens DiabetesPedigreeFunction er under 2,5). Jeg bruker derfor standardScaler for modeller som er følsomme for skala, som logistisk regresjon. Trebaserte modeller trenger ikke skalering. Rensing og skalering legges i en scikit-learn-`Pipeline`, slik at nøyaktig de samme stegene brukes på nettsiden.

Personvern og etikk

- Datasettet inneholder kun kvinner over 21 år med Pima-indiansk bakgrunn. Modellen kan derfor ikke uten videre brukes på menn, yngre personer eller andre befolkningsgrupper.
- Nettsiden informerer om at resultatet kun er et estimat, og at man må kontakte lege for diagnose.
- En falsk negativ kan gi en syk person falsk trygghet. Dette er hovedgrunnen til at man prioriterer recall.
- Personvern. Datasettet er anonymisert. Nettsiden lagrer ikke data som brukeren legger inn, siden helseopplysninger er særlig sensitive etter GDPR.
- Dataene stammer fra en navngitt urfolksgruppe som har vært gjenstand for langvarig medisinsk forskning. Det reiser spørsmål om samtykke og om hvordan gruppen fremstilles i videre bruk av dataene (Radin, 2017).

Modellering

Baseline

Jeg har laget to baselines som modellene må slå. Den første gjetter alltid at pasienten er frisk. Den oppnår 64,9 % accuracy, men finner ingen av de syke. Det viser at accuracy alene ikke er et godt mål for dette problemet. Den andre baselinen er en enkel regel uten maskinlæring: pasienten klassifiseres som syk dersom blodsukkeret er 125 eller høyere. Terskelen ble valgt ut fra treningsdataene. På testsettet identifiserte regelen 34 av 54 pasienter med diabetes, mens 20 ble oversett og 29 friske ble feilaktig klassifisert som syke. Tidligere studier på samme datasett oppnår vanligvis en accuracy på rundt 75–80 % (Khanam & Foo, 2021).

Modeller

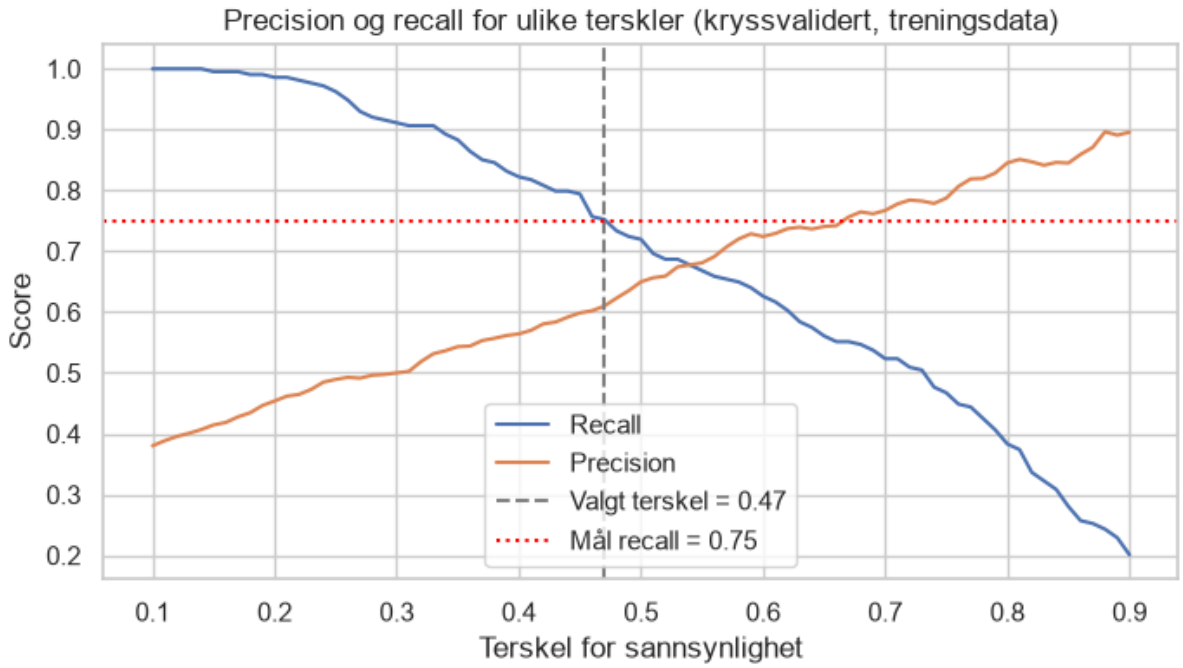
Jeg har sammenlignet tre modeller: logistisk regresjon, random forest og gradient boosting. Alle modellene er bygget som en scikit-learn-pipeline der 0-verdiene erstattes med medianen fra treningsdataene. Logistisk regresjon får i tillegg skalering med StandardScaler. Fordi datasettet er ubalansert, brukte jeg `class_weight="balanced"` for logistisk regresjon og random forest, slik at de syke pasientene får større vekt under treningen.

Modellene ble sammenlignet med 5-fold kryssvalidering på treningsdataene, og hyperparametrene ble tunet med grid search. Under tuningen brukte jeg ROC AUC som mål, fordi den viser hvor godt modellen skiller mellom syke og friske uavhengig av

terskel. Logistisk regresjon fikk høyest resultat (ROC AUC 0,845), foran random forest (0,838) og gradient boosting (0,830), og ble derfor valgt som endelig modell.

Valg av terskel

Vanligvis sier modellen «diabetes» når sannsynligheten er 50 % eller høyere. Siden recall er hovedmetrikken, valgte jeg i stedet den høyeste terskelen som ga recall på minst 0,75 i kryssvalideringen. Det ga en terskel på 0,47 (se figur 1).



Figur 1: Precision og recall for ulike terskler. Lavere terskel gir høyere recall, men lavere precision. Laget med matplotlib (Hunter, 2007).

Resultater på testsettet

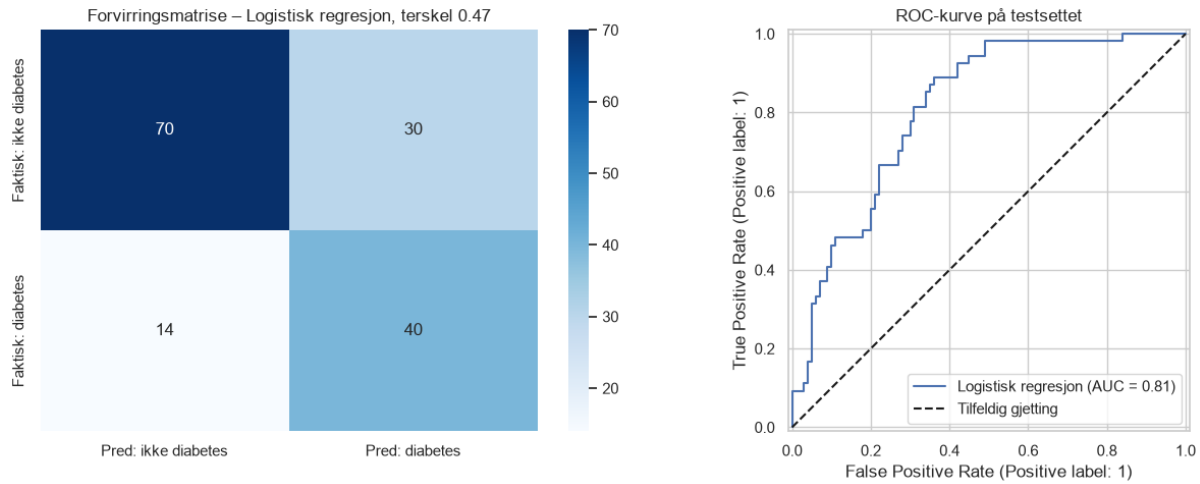
Modell	Accuracy	Precision	Recall	F1	ROC AUC
Baseline: alltid «ikke diabetes»	0,649	0,000	0,000	0,000	
Baseline: Glucose ≥ 125	0,682	0,540	0,630	0,581	
Logistisk regresjon (terskel 0,50)	0,708	0,571	0,667	0,615	0,810
Random Forest	0,727	0,588	0,741	0,656	0,811

(terskel 0,50)					
Gradient Boosting (terskel 0,50)	0,714	0,614	0,500	0,551	0,811
Logistisk regresjon (terskel 0,47)	0,714	0,571	0,741	0,645	0,810

Tabell: Resultater på testsettet (154 pasienter, hvorav 54 med diabetes).

Den endelige modellen fant 40 av 54 syke pasienter, mot 34 med blodsukker-regelen, og ga omtrent like mange falske alarmer (30 mot 29). Recall økte fra 0,63 til 0,74, og F1 fra 0,58 til 0,65. Modellen slår dermed baselinen. Målet om recall på 0,75 ble nesten nådd. Siden testsettet bare har 54 syke, utgjør én pasient ca. 2 prosentpoeng.

Random forest fikk litt høyere F1 på testsettet, men jeg valgte modell ut fra kryssvalideringen og ikke testsettet, fordi testsettet kun skal brukes til den endelige evalueringen. Alle tre modellene har nesten lik ROC AUC på testsettet (0,81). Accuracy (71 %) er litt lavere enn i andre studier, fordi jeg bevisst senket terskelen for å finne flere syke. I kryssvalideringen var accuracy 76 %.

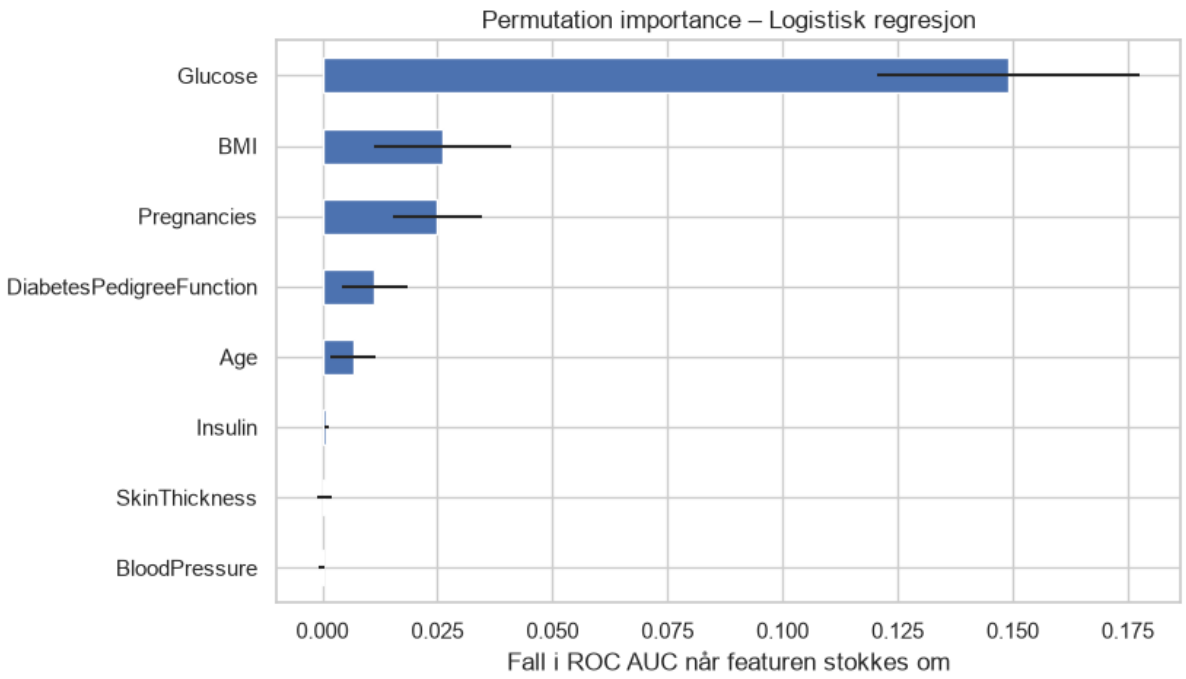


Figur 2: Forvirringsmatrise og ROC-kurve for den endelige modellen på testsettet. Laget med matplotlib og seaborn (Hunter, 2007; Waskom, 2021).

Feature importance

For å se hvilke målinger modellen bruker mest, brukte jeg permutation importance. Da stokkes én måling om om gangen, og man ser hvor mye resultatet blir dårligere. Blodsukker (Glucose) er klart viktigst, etterfulgt av BMI, antall graviditeter, arvelighet (DiabetesPedigreeFunction) og alder. Insulin, hudfoldtykkelse og blodtrykk bidrar

nesten ingenting. Det kan skyldes at Insulin og SkinThickness mangler for mange pasienter, og at informasjonen deres delvis overlapper med BMI og blodsukker.



Figur 3: Hvor mye ROC AUC faller når hver måling stokkes om. Lengre stolpe betyr viktigere måling. Laget med matplotlib (Hunter, 2007).

Analyse av feilprediksjoner

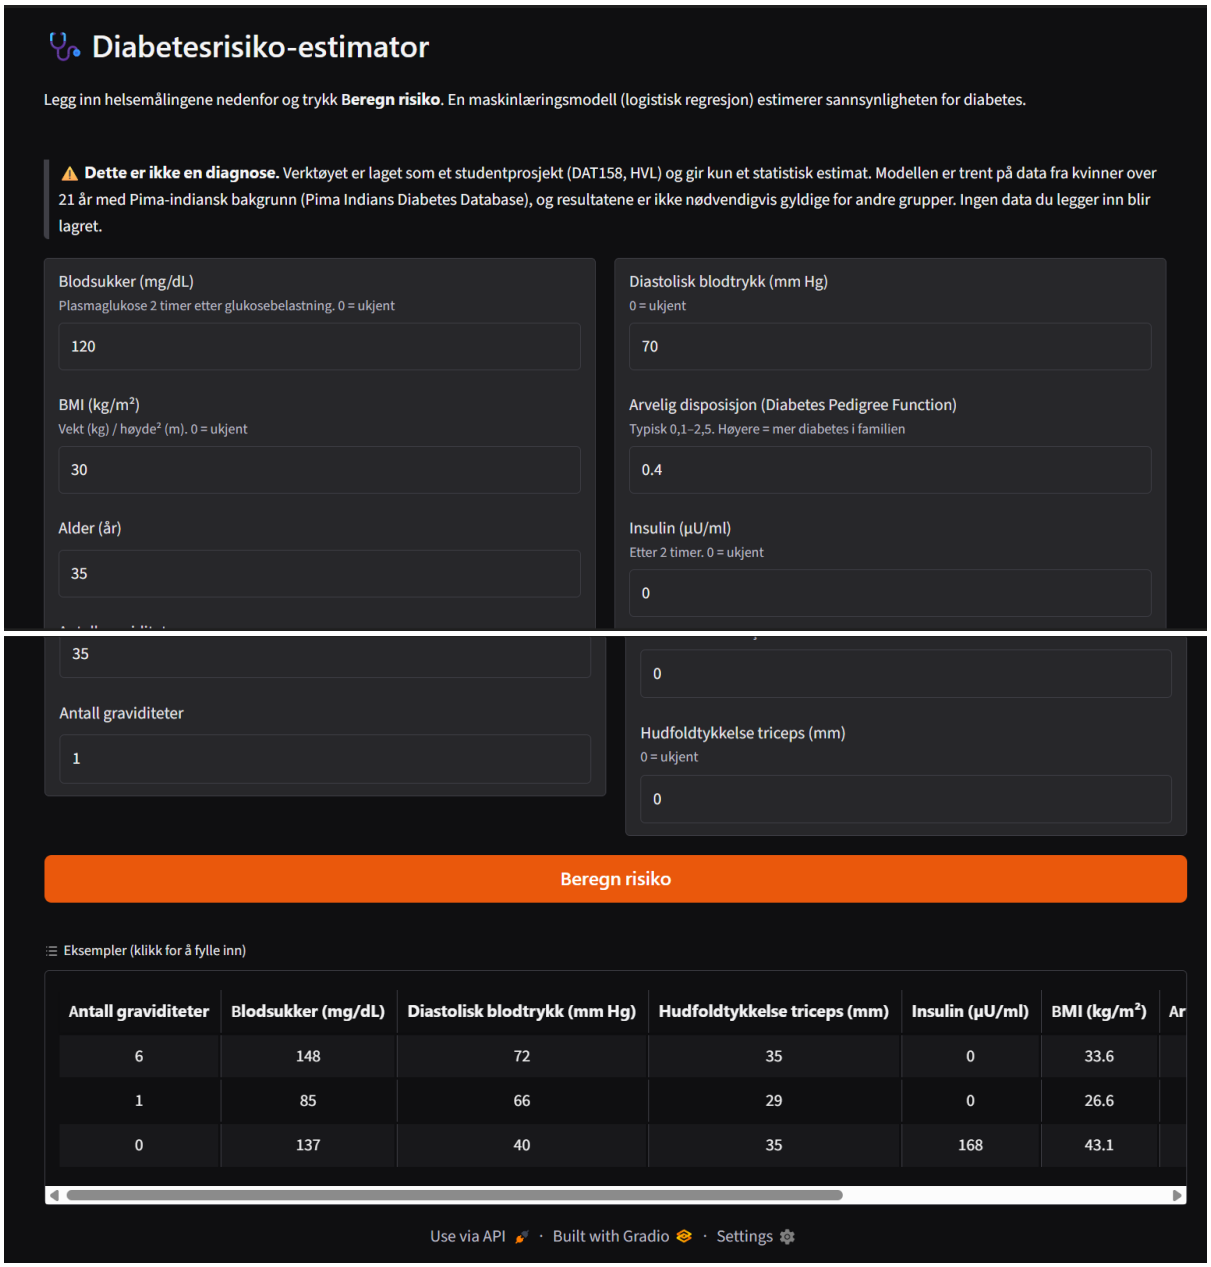
Jeg undersøkte de 14 syke pasientene som modellen overså. De hadde i snitt lavere blodsukker (114 mot 149 for de syke som ble funnet), var yngre (29 mot 39 år), og 10 av 14 manglet insulinverdi. Modellen sliter altså med pasienter som har diabetes uten typiske risikoverdier. Dette kan forbedres med mer data, særlig fra yngre pasienter, og bedre håndtering av manglende verdier, for eksempel ved å legge til en egen variabel som viser om verdien manglet.

Deployment

Hvordan modellen er satt i drift

Den ferdigtrente modellen er lagret som én fil (diabetes_model.joblib). Filen inneholder hele scikit-learn-pipelinen, altså erstatning av manglende verdier, skalering og logistisk regresjon, sammen med den valgte terskelen på 0,47. Nettsiden er laget med Gradio (Abid et al., 2019) og ligger i filen app.py. Når brukeren trykker «Beregn risiko», sendes de åtte verdiene til modellen, som returnerer en sannsynlighet for diabetes. Er sannsynligheten 47 % eller høyere, vises «Forhøyet risiko» med anbefaling om å kontakte lege. Ellers vises «Lav risiko».

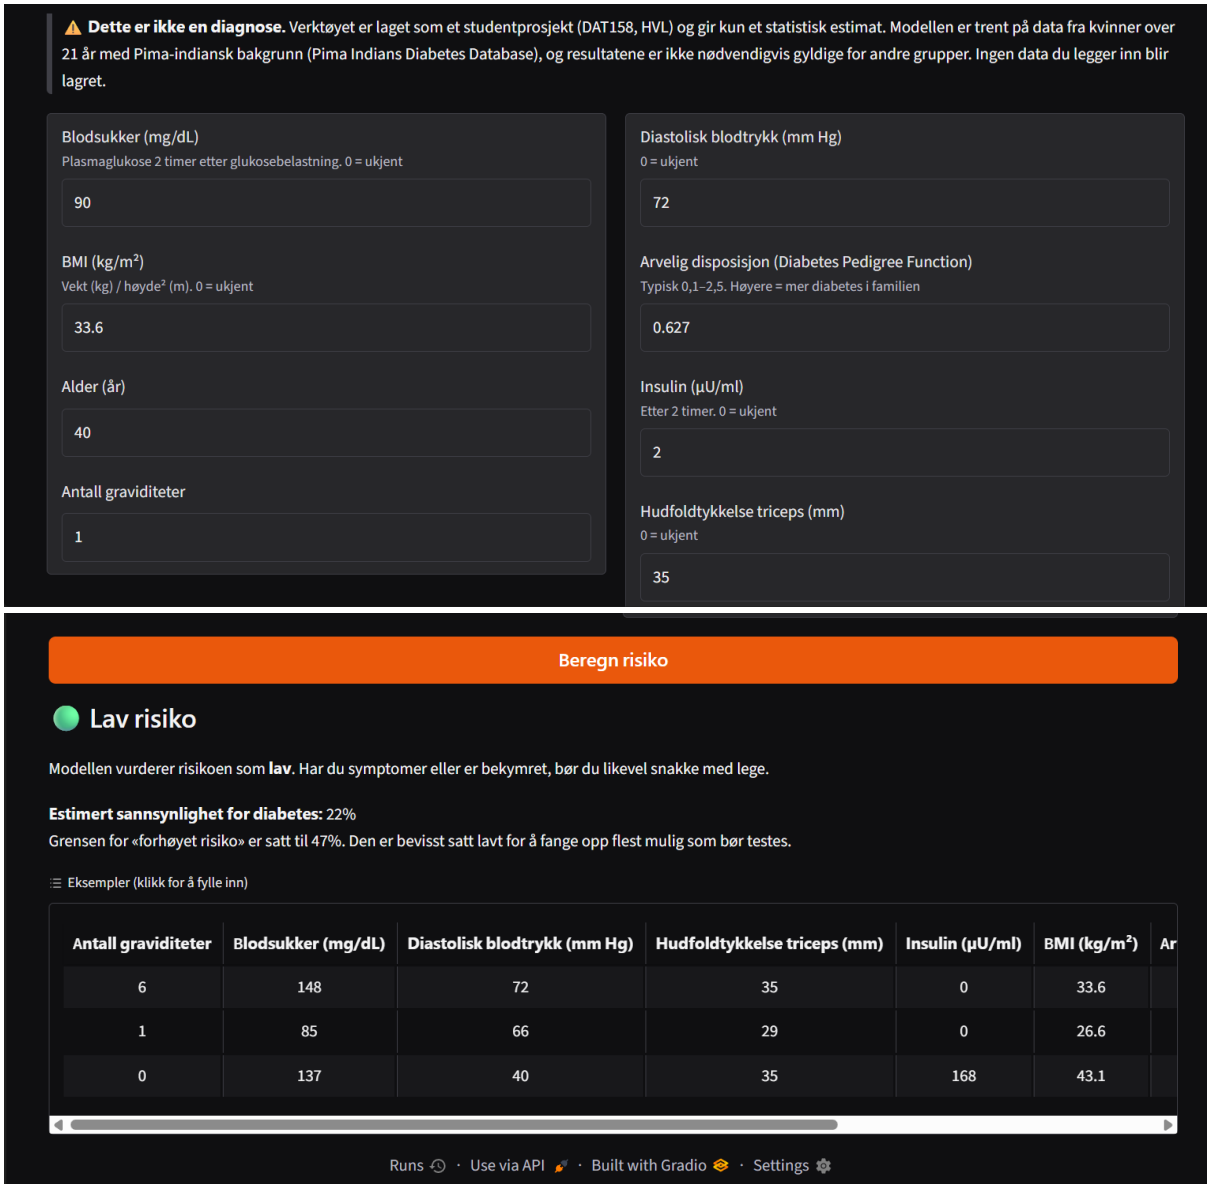
Bilder av nettsiden

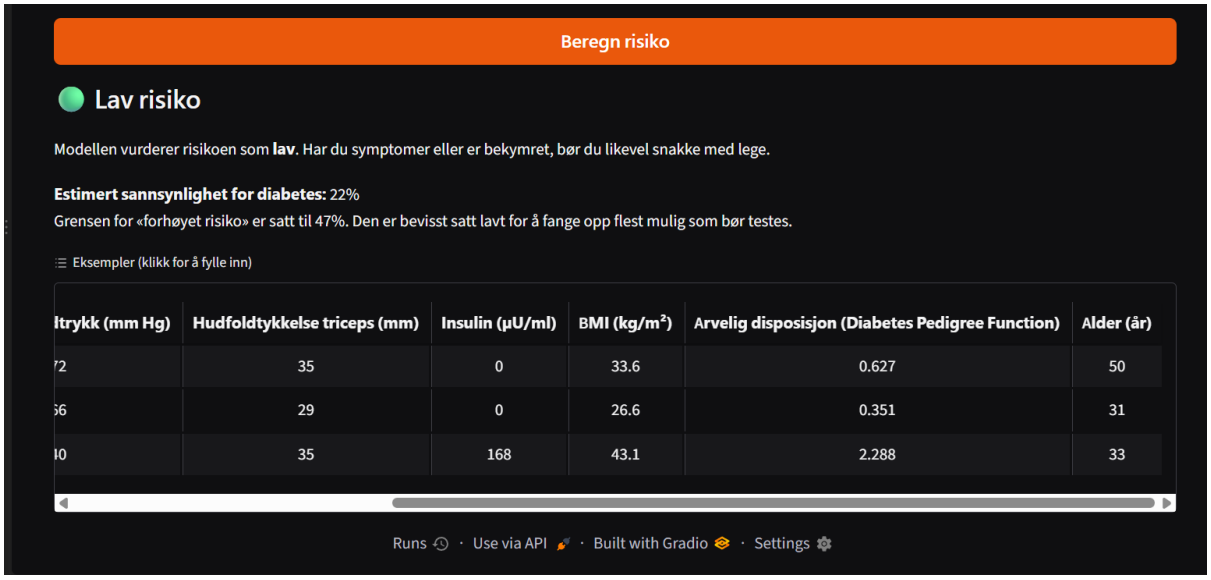


Hvordan prediksjonene skal brukes

Prediksjonen er ment som en førstevurdering og ikke en diagnose. Nettsiden viser derfor tydelig at resultatet kun er et estimat, at modellen er trent på en begrenset gruppe (kvinner over 21 år med Pima-indiansk bakgrunn), og at man må kontakte lege for videre testing. Hvis en verdi er ukjent, kan brukeren skrive 0, og nettsiden viser hvilke verdier som ble erstattet med typiske verdier. Ingen data som legges inn blir lagret.

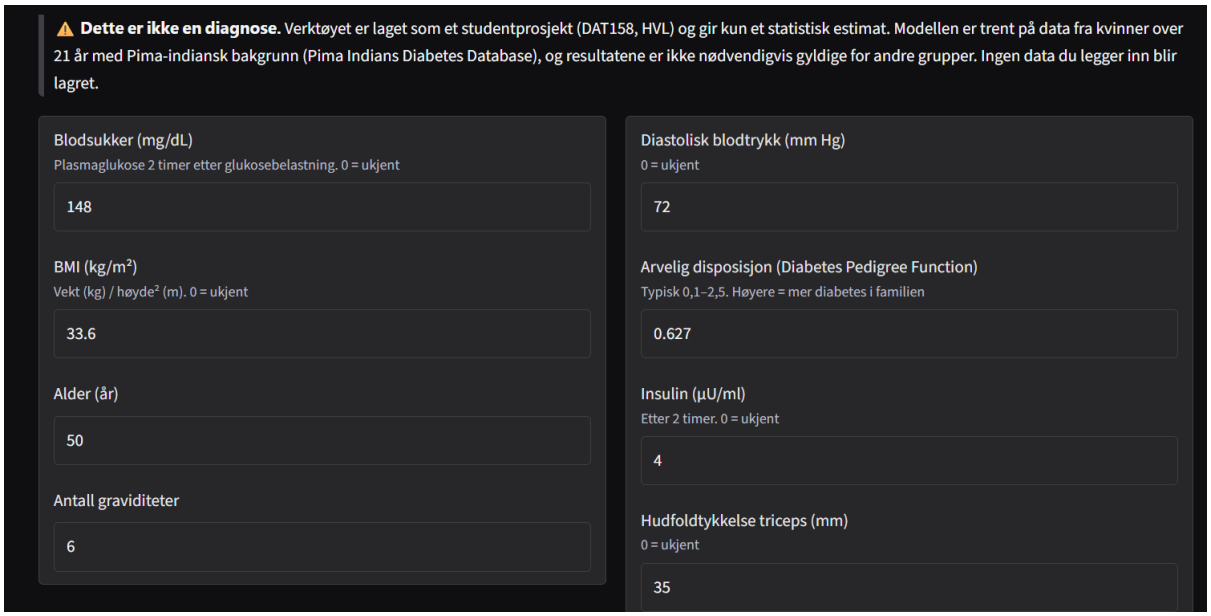
Lav risiko

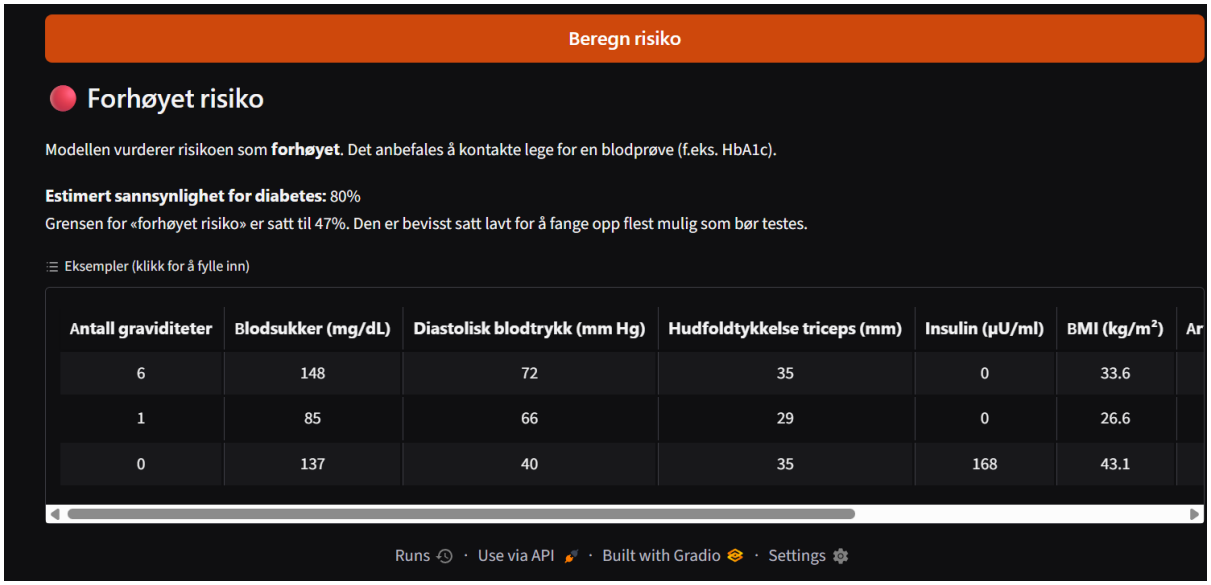

⚠ Dette er ikke en diagnose. Verktøyet er laget som et studentprosjekt (DAT158, HVL) og gir kun et statistisk estimat. Modellen er trent på data fra kvinner over 21 år med Pima-indiansk bakgrunn (Pima Indians Diabetes Database), og resultatene er ikke nødvendigvis gyldige for andre grupper. Ingen data du legger inn blir lagret.
Blodsukker (mg/dL)
Plasmaglukose 2 timer etter glukosebelastning. 0 = ukjent
90
BMI (kg/m²)
Vekt (kg) / høyde² (m). 0 = ukjent
33.6
Alder (år)
40
Antall graviditeter
1
Diastolisk blodtrykk (mm Hg)
0 = ukjent
72
Arvelig disposisjon (Diabetes Pedigree Function)
Typisk 0,1–2,5. Høyere = mer diabetes i familien
0.627
Insulin (µU/ml)
Etter 2 timer. 0 = ukjent
2
Hudfoldtykkelse triceps (mm)
0 = ukjent
35
Beregn risiko
Lav risiko
Modellen vurderer risikoen som lav. Har du symptomer eller er bekymret, bør du likevel snakke med lege.
Estimert sannsynlighet for diabetes: 22%
Grensen for «forhøyet risiko» er satt til 47%. Den er bevisst satt lavt for å fange opp flest mulig som bør testes.
Eksempler (klikk for å fylle inn)
Antall graviditeter | Blodsukker (mg/dL) | Diastolisk blodtrykk (mm Hg) | Hudfoldtykkelse triceps (mm) | Insulin (µU/ml) | BMI (kg/m²) | Ar
6 | 148 | 72 | 35 | 0 | 33.6
1 | 85 | 66 | 29 | 0 | 26.6
0 | 137 | 40 | 35 | 168 | 43.1
Runs · Use via API · Built with Gradio · Settings



Figur 4: Eksempel på en pasient som får lav risiko.

Høy risiko





Figur 5: Eksempel på en pasient som får forhøyet risiko.

Nettsiden kjører lokalt ved å starte filen app.py (`python app/app.py`) og åpnes i nettleseren på adressen http://127.0.0.1:7860. En video som viser nettsiden i bruk, med ett eksempel på forhøyet risiko og ett på lav risiko, ligger i GitHub-repoet i mappen video (video/demo.mp4). All kode og instruksjoner for å reprodusere resultatene og starte nettsiden ligger også i repoet og er beskrevet i README-filen.

Referanser

Abid, A., Abdalla, A., Abid, A., Khan, D., Alfozan, A., & Zou, J. (2019). Gradio: Hassle-free sharing and testing of ML models in the wild (arXiv:1906.02569). arXiv. https://doi.org/10.48550/arXiv.1906.02569

Anthropic. (2026). Claude (Opus 5.5) [Stor språkmodell]. https://claude.ai

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. Computing in Science & Engineering, 9(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

Khanam, J. J., & Foo, S. Y. (2021). A comparison of machine learning algorithms for diabetes prediction. ICT Express, 7(4), 432–439. https://doi.org/10.1016/j.icte.2021.02.004

Norsk Helseinformatikk. (u.å.). Type 2-diabetes – årsaker, behandling og kosthold. NHI.no. Hentet (04.10.26) fra https://nhi.no/sykdommer/hormoner-og-naring/diabetes-type-2/type-2-diabetes-oversikt

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Radin, J. (2017). "Digital natives": How medical and Indigenous histories matter for big data. Osiris, 32(1), 43–64. https://doi.org/10.1086/693853

Smith, J. W., Everhart, J. E., Dickson, W. C., Knowler, W. C., & Johannes, R. S. (1988). Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. Proceedings of the Annual Symposium on Computer Application in Medical Care, 261–265.

UCI Machine Learning. (2016). Pima Indians Diabetes Database [Datasett]. Kaggle. https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database

Waskom, M. L. (2021). seaborn: Statistical data visualization. Journal of Open Source Software, 6(60), 3021. https://doi.org/10.21105/joss.03021

Bruk av KI-verktøy

Jeg har brukt KI-verktøy underveis i prosjektet, hovedsakelig Claude (Anthropic, 2026). KI ble brukt til veiledning i oppsett av Python-miljø og GitHub, til forslag om datasett og metrikker, til førsteutkast av kode for dataanalyse, modellering og nettside, og til utkast og språklig bearbeiding av rapporten. Jeg har selv kjørt all kode, vurdert resultatene og tatt valgene i prosjektet, og alle tall i rapporten kommer fra mine egne kjøringer. All KI-generert tekst og kode er gjennomgått og tilpasset av meg, og jeg står ansvarlig for innholdet.